

Subsetting elements

selected_element ← my_matrix[my_matrix > 10]

- accessing elements
matrix[, 3] 3rd column / matrix[2, 3] second row, 3rd column
- transpose
t(my_matrix)
- multiplication, addition
my_matrix %*% another_matrix, matrix1 + matrix2
- Combine vertically
combined_matrix ← rbind(matrix1, matrix2)
- Selecting elements based on sequence
matrix[, m[1,] > 2] # select columns for which 1st row is > 2.
- diag(A), diag(n).
- Reshape matrix : dim(matrix) ← c(2, 3)

Arrays

(Multi dimensional data structures)

- create array : my_array ← array(1:18, dim=c(3, 3, 2))
- accessing elements : element ← my_array[2, 3, 1]
row col depth
- subarray : sub_array ← my_array[1:2, 1:2, 1]
- transpose : transposed_array ← aperm(my_array, c(3, 2, 1))
- dimension set : dim(array) ← c(2, 3, 3).
- * - names to array : dimnames(my_array) ← list(c("Row1", "Row2", "Row3"),
c("col1", "col2", "col3"))
- reshaping : reshaped_array ← aperm(array, c(3, 2, 1)) c("Depth1", "Depth2")

Data frames

- data1 ← data[data\$age > 25,] : Select column with condition.
- columns ← data[, c('age', 'name')] : Select multiple columns
- sorted_data ← data[order(data\$age, decreasing = TRUE),]
azırtma, decreasing = FALSE)]
- Subset - subset_data ← subset(data, age > 25)
- * - Transformation azırtır : new_data ← transform(data, new_col = age * 2)

- Δύο περιπτώσεις, ένα δείγμα:

```
selected_rows <- data[(data$Income < 100) &  
(data$Income > 1000),]
```

Booster

- `Rm(list = list())` = καθαρίζει το R

- `save.image(file = "df.RData")`

- Recycle R: εάν προσέσω ένα vector με 10 στοιχεία σε ένα δείγμα με 5, τότε θα προσέσω μόνο 5 φορές.

- `data[-c(X,Y)]` κόβει τα με NaN. στοιχεία

- 6α περίπτωση seq βάλω -0.5.

Apply family

apply: operate functions in specific parts of an array.

Suppose we want to find median for every column

- `apply(state.x77, 2, median)`

- `apply(data, 2, median, c(0.25, 0.75))`

Acumen

- `column-sums <- apply(data, 2, sum)`

- `new_data <- rbind(data, column-sums)`

lapply: applies a function to every element in a list and returns a list.

- `my_list <- list(a = 1:3, b = 4:6, c = 7:9)`

`result <- lapply(my_list, mean)`

`result <- lapply(dataframe, sum) # Same to dataframe`

sapply: returns a vector or matrix. 's' → simplify

- `data_means <- sapply(data, mean)`

Adds from an expression

* `apply(state.x77, 2, quantile, c(0.25, 0.75))`

Σε κάθε αλλαγή ή υπολογισμό μετά ή πριν τη παροχή βοήθειας ";"
για να προσδιορίσετε αλλαγές σε δεδομένα ή ερωτήσεις.

★ Διαγράφι low correlated variables

```
cors <- sapply(pred, cor, y = response) # calculate correlations
mask <- (rank(-abs(cors)) <= 10)
```

★ Εύρεση μεγάλων συσχετίσεων: `cor-values <- sapply(data, function(col),`
`selected_cols <- names(cor-values[cor...]) cor(col, data[, 7]) > 0.75)`

tapply: Ομαδοποιεί και υπολογίζει λειτουργίες σε data.frames βάσει ενός factor. Π.χ. `tapply(X, F, fun)` f=factor βάσει, X=vector

- chickwts: weight = numeric, feed = factor.

`tapply(chickwts[, weight], chickwts[, feed], mean, sd, length etc.)`

Αφαίρεση στήλων

for replace:

```
remove_col <- c("X1", "X2" ...)
```

```
new_df <- df[, !(names(df) %in% remove_col)]
```

for replace:

```
clear_data <- subset(data, select = -c("col1", "col2"))
```

Υπολογισμός στατιστικών με apply

```
descriptives_df <- data.frame(
```

```
  min = sapply(df, function(x), min(x, na.rm = TRUE)),
```

```
  quantile = sapply(df, function(x), quantile(x, 0.25, na.rm = TRUE)),
```

```
  mean = sapply(df, function(x), median(x, na.rm = TRUE)) )
```

Sequences και κατανομές

- `rnorm(n, meanmu, sdsigma)` (generate)

- `pnorm(x, mu, sigma)` (linear $\Phi(x)$)

- `dnorm(x, mu, sigma)` (slope)

- `qnorm(0.95, mu, sigma)` (given 95%)

cor. or p-value critical value

^{number of trials}
`rbinom(nn, pp)` → prob.

`pbinom(x, n, p)`

`dbinom(x, n, p)`

`qbinom(0.95, n, p)`

- `seq(from = value, to = value, by = value, length.out = value)`
- `seq(0, 20, 4)`
- `seq(20, 1, -1)`
- `replicated_seq <- rep(1:3, times = 3)`
- `paste("no", 1:5)` → νέες no με αριθμ διατά.
- `paste("no", 1:5, sep = " ")` χωρίς κενά για strings

Διαστήματα εμπιστοσύνης

$$\bar{X} \pm Z_{1-\alpha/2} \sqrt{6/n}, \quad \bar{X} - \bar{Y} \pm Z_{1-\alpha/2} \sqrt{6x^2/n + 6y^2/m}$$

Παράδειγμα 1: Έχω ένα data sample

```
conf-interval <- t.test(sample_data)$conf.int. # default 95%
conf-int 90 <- t.test(sample_data, conf.level = 0.90)$conf.int
print(conf-int)
```

Παράδειγμα 2: Χρειαζόμαστε το μέγεθος του δείγματος για να έχουμε

```
n = 175
mean <- mean(data), sd_value <- (sqrt(sum((x - mean)^2) / (n - 1)))
t_value <- qt(Z_{1-\alpha/2}, df = n - 1)
ci_lower <- mean - t_value * (sd_value / sqrt(n))
ci_upper <- mean + t_value * (sd_value / sqrt(n))
print(paste("...", ci_lower, ci_upper))
```

Άσκηση

Έχω το UKDriversDeaths dataset. Να βρω το 95% CI για τον μέσο των θανάτων ανά μίλι για κάθε χώρα.

Hint: χρειαζόμαστε apply ονομάζω data το set.

```
Xbars <- apply(data, 2, mean), sds <- apply(data, 2, sd)
n <- nrow(data), Z <- 1.96
standar-error <- sds / sqrt(n)
```


Για να υπολογίσω μία πιθανότητα
βρίσκω από $qnorm(0.975) = 1.96$

```
lower_CI ← xbars - Z · standard-error.  
upper_CI ← xbars + Z · standard-error.  
print(paste( ..., lower_CI, upper_CI))  
αλλά ως  $Z ← qnorm(0.975)$  αντί να δώσουμε φέρει τον αριθμό
```

Ανάλυση

Έχω ένα dataset με 1 numeric και factor. Να βρω το διάστημα
95% για τον μέσο των 9 ομάδων.

1ος:

```
xbars ← tapply(data$score, data$team, mean)  
sds ← tapply(..., n ← tapply(...)  
Z ← qnorm(0.975)  
standard-error ← sds / sqrt(n)  
lower_CI ← xbars - (Z · st...) Upper_CI ← xbars + (Z · st...)  
print(paste(lower_CI, upper_CI))
```

2ος:

```
result ← tapply( numeric factor, function(x) t.test(x)$conf.int)  
print(result)
```

• Διαβάσμα αρχείου: `dec = ','` εάν έχει κόμμα μέσα το να γίνει τμήμα

Ελέγχοι Υποθέσεων test

t.test: `t.test(sample-data, mu = expected-mean)` #1 sample
`t.test(group1, group2)` #2 sample

► `t.test(x, y = null, alternative = c("two.sided", "less", "greater"), mu = 0,
paired = FALSE, var.equal = FALSE, conf.level = 0.95)`

• Από default αν δώσω το `t.test` να έχω 168 διαυγώνεις, αλλά:
`var.test(group1, group2)` ελέγχουμε με F-test.
`t.test(group1, group2, var.equal = TRUE)`

`paired = FALSE` τα δείγματα είναι ανεξάρτητα
`paired = TRUE` είναι συσχετισμένα ή `paired`

• Extract p-value: $p\text{-value} \leftarrow \text{result}\$p\text{-value}$

less"

$H_0: \mu = 75$, $H_1: \mu \leq 75$

$t\text{-test_result} \leftarrow t.test(\text{sample}, \mu = 75, \text{alternative} = "less")$

groups $\alpha = 0.05$

```
if (alpha > p-value) {  
  cat("reject null hypothesis")  
} else {  
  cat("fail to reject null hypothesis")  
}
```

• $\text{Wilcox.test}(\text{group1}, \text{group2})$

Regression

Stepwise AIC

$\text{lm}(Y \sim ., \text{data} = \text{data})$

$\text{influence.measures}(\text{model})$
 $\text{confint}(\text{fit})$

- $\text{stepAIC}(\text{model}, \text{direction} = "forward")$ uau zupis zo AIC
- $\text{stepAIC}(\text{model}, \text{direction} = "backward")$
- $\text{stepAIC}(\text{model}, \text{direction} = "both")$

Stepwise BIC

- $\text{step}(\text{model}, K = \log(\text{length}(x)), \text{direction} = "backward")$
- $\text{step}(\text{model}, K = \log(\text{length}(x)), \text{direction} = "forward")$
- $\text{direction} = "both"$

Predictions, Plots and style

Predictions

$\text{confint}(\text{fit}) = \text{pizidvra } \delta \text{ idozupa } \gamma \text{ a za coefficients.}$

• $\text{mu.hat} \leftarrow \text{predict}(\text{fit}, \text{interval} = "confidence")$
pion zipu zur predictions.

• $\text{y.hat} \leftarrow \text{predict}(\text{fit}, \text{interval} = "prediction")$
y uanizlo me idozupa

★ Προσέδωμεν μία δεδομένη
 enothetismos xbar=mu, sd=s, uae bijartas } συνδυασμός με
 rnorm(1, xbar, sd) → βίντεο video } apply για να το
 uakw ymallois sthlist.

φτιάχνω ένα νέο data frame. η βειρα-row uae το bijan

6za predict apply(data, ? mean, sd

explanatory-data ← data.frame(

opifw
 tous apothetis. $X1 = rnorm(1, xbars[1], sds[1], \dots)$

predict(model, explanatory-data) → zo vto j.

Plots.

- Setting the layout.

par(..... c(2,2), bg="...") pch=16 για fill

Plot every explanatory vs fitted.

$fitted \leftarrow fitted(model)$

- plot(data\$X1, model\$residuals, main="fitted vs predicted X1")

- abline(h=0, col="red")

fitted vs residuals : plot(model\$residuals, fitted-values)

Διάστημα 95% για τα regression coefficients

CI ← confint(model, level = 0.95)

★ Διαγράψι εντοπισμός ziplw influence ← dataframe, order → διαγράψι
 za megalozeza cooks.distance

Extract R²: summary(model)\$r.squared

★ New predictions με CI 95%:

φτιάχνω za vto data: new-predictions ← predict(model, explanatory,
 interval="confidence", level=0.95)

★ New predictions με CI 95% για το response:

observed-predictions ← predict(model, explanatory,
 interval="prediction", level=0.95)

★ cook ← influence\$ cooks.distance

threshold ← 4/nrow(data) (zo 4% zo a2dijw)

Influential-obs ← which(cook > threshold)

clean_data ← data[cook <= threshold,]

new-model ← lm(Y ~ ., data = clean_data)

Matrices

(two dimensional data structure)

- Construct matrix

```
matrix(1:9, nrow=..., ncol=...)
```

```
matrix(rnorm(6*4, mean=0, sd=1, nrow=..., ncol=..., byrow=TRUE))
```

- Combine Vectors

```
vect1 ← c(...)
```

```
vect2 ← c(...)
```

```
vect3 ← c(...)
```

```
mymatrix ← c(vect1, vect2, vect3)
```

```
matrix ← matrix(mymatrix, byrow=TRUE, nrow=3)
```

Define as ~~rows~~ ~~columns~~

ii

```
mymatrix ← cbind(vect1, vect2, vect3) # 2 binders
```

- Assign names to matrix

```
colnames(my.matrix) ← c("var1", "var2", ...)
```

```
rownames(my.matrix) ← c("x", "y", "z")
```